

APRENDIZADO DE MÁQUINA UTILIZANDO MÉTODO DE ELEMENTOS FINITOS E ARITMÉTICA INTERVALAR

Danillo Roberto Pereira



Faculdade de Ciências e Tecnologia - Unesp
R. Roberto Simonsen, 305 - Centro Educacional,
Presidente Prudente - SP - Brasil

Novembro de 2024

Resumo

Os avanços significativos na área de Aprendizado de Máquina nas últimas décadas são atribuídos, em grande parte, à utilização, criação e combinação de métodos matemáticos e estatísticos. Nesse contexto, destacam-se a Aritmética Intervalar (ArI) e o Método de Elementos Finitos (FEM), introduzidos inicialmente na área de aprendizado de máquina pelo autor desta proposta. Diante disso, a presente pesquisa tem como objetivo aplicar e expandir o uso de diversas metodologias matemáticas pouco exploradas ou não utilizadas no campo do aprendizado de máquina, buscando trazer inovações significativas para a área. O projeto será desenvolvido em três frentes distintas: (i) utilização do robusto ferramental do Método de Elementos Finitos para a criação de novos algoritmos de aprendizado de máquina; (ii) aprimoramento dos métodos de aprendizado de máquina baseados no framework FEMa (Finite Element Machine), desenvolvido pelo autor; e (iii) aplicação da metodologia de Aritmética Intervalar em contextos que apresentam dependências espaciais e/ou temporais.

Conteúdo

1	Introdução	4
2	Referencial Teórico	5
2.1	Método de Elementos Finitos	5
2.1.1	Definições	5
2.1.2	Finite Element Machine Classifier	8
2.2	Aritmética Intervalar	12
2.2.1	Conceitos Gerais	12
2.2.2	Aplicação em Aprendizado de Máquina Contextual	12
3	Objetivos	14
4	Justificativa	14
5	Metodologia	15
5.1	Extensão e Otimização do <i>Framework</i> FEMa	15
5.2	Aritmética Intervalar (ArI)	15
6	Resultados Esperados	16
7	Cronograma	16
8	Identificação dos Participantes do Projeto	17

1 Introdução

O Aprendizado de Máquina (AM) é uma subárea da Inteligência Artificial (IA) que se dedica ao desenvolvimento de algoritmos e modelos capazes de aprender de forma automática, extraindo padrões e informações relevantes a partir de um conjunto de amostras de exemplo. Esses métodos são fundamentados em um vasto ferramental matemático e estatístico, permitindo uma análise profunda de dados complexos e, muitas vezes, de alta dimensionalidade. A versatilidade das técnicas de AM possibilita uma ampla gama de aplicações em diversas áreas do conhecimento, especialmente naquelas onde há a necessidade de extrair conhecimento significativo de grandes volumes de dados. Exemplos notáveis incluem diagnóstico médico [9], onde a AM é utilizada para identificar doenças a partir de exames clínicos; a classificação de imagens de satélite [8, 10], que auxilia na monitorização ambiental e no planejamento urbano; e a identificação de furto de energia [14], que melhora a eficiência na gestão de recursos energéticos.

As técnicas de AM podem ser divididas em dois grupos básicos: (i) métodos discriminativos, que se concentram na modelagem das fronteiras de decisão entre classes, otimizando a separação de dados; e (ii) métodos generativos, que buscam modelar a distribuição dos dados, permitindo a geração de novas amostras semelhantes às do conjunto original. Essa categorização não apenas fornece um entendimento mais claro sobre as abordagens disponíveis, mas também orienta a escolha da técnica mais adequada conforme os objetivos específicos de cada aplicação. Assim, a AM se configura como uma ferramenta poderosa e indispensável na era dos dados, contribuindo para avanços significativos em diversas disciplinas e setores da sociedade.

Os métodos de AM generativos são algoritmos desenvolvidos para construir novos dados (imagens, texto, música ou outros tipos de conteúdo) que diferem dos utilizados na etapa de treinamento. Esses métodos têm a capacidade de criar exemplos "inéditos" que se "assemelham" aos dados originais utilizados no treinamento, oferecendo um grande potencial para inovação e criatividade em aplicações práticas. Em contraste, os métodos de AM discriminativos, após uma etapa de treinamento, buscam prever classes ou valores reais, sendo fundamentais em tarefas onde a precisão da previsão é crítica.

Os métodos de aprendizado de máquina discriminativos podem ser divididos em duas categorias básicas: aprendizado supervisionado e não supervisionado. Os métodos de aprendizado supervisionado utilizam um conjunto de amostras pré-rotuladas (comumente referido como conjunto de treinamento) para extrair padrões desses exemplos e, posteriormente, aplicá-los em amostras de teste. Cada uma das amostras dos conjuntos de treino e teste é composta por um conjunto de características de entrada e um rótulo que representa sua classe ou um valor real a ser previsto (quando este estiver disponível). Deste modo, esses métodos exigem a rotulação das amostras *a priori* por um "especialista". Assim, caso o rótulo seja um valor discreto, tem-se um problema de classificação; caso contrário (rótulo contínuo), um problema de regressão.

Em diversas aplicações, a rotulação das amostras do conjunto de treinamento pode ser inviável, seja devido ao elevado custo associado ao processo, à complexidade da tarefa ou à ausência de necessidade explícita de rotulação. Nessas situações, recorrem-se a métodos de aprendizado não supervisionado, os quais dispensam a pré-classificação das amostras do conjunto de treinamento. Tais métodos têm como principal objetivo identificar agrupamentos de amostras que apresentam menor discrepância entre si, com base em uma métrica de similaridade previamente definida, favorecendo, assim, uma análise exploratória mais aprofundada dos dados.

No contexto de métodos de AM que utilizam aprendizado supervisionado, seja para regressão ou classificação, após a fase de treinamento é necessário avaliar a qualidade do modelo gerado. Para tal, utiliza-se comumente um conjunto de teste ou validação, cujas amostras são rotuladas. No caso de um problema de classificação, cada amostra do conjunto é classificada pelo modelo, e o rótulo predito é comparado ao rótulo verdadeiro. Se os rótulos coincidirem, considera-se um acerto; caso contrário, ocorre um erro de classificação. No caso de regressão, a diferença entre o valor predito e o valor real é utilizada para calcular métricas de erro, como o erro médio absoluto ou o erro quadrático médio. Com base nesses critérios, é possível calcular a acurácia ou a qualidade do modelo empregado, que são utilizados como métricas de desempenho. Além disso, métricas que consideram o tempo de processamento também podem ser aplicadas, especialmente em aplicações que requerem processamento em tempo real, assegurando a eficácia e eficiência dos modelos desenvolvidos em cenários práticos.

Na área da IA, muitos avanços recentes têm sido obtidos devido à utilização e ao desenvolvimento de métodos matemáticos e estatísticos, o que comprova a importância da aplicação e criação de novas

metodologias matemáticas nesse campo. Destaca-se, neste contexto, o trabalho de Pereira e Papa [12], que resgataram a Aritmética Intervalar (ArI) da década de 1960 e a aplicaram com sucesso no processo de classificação contextual de imagens de satélite. Essa aplicação resultou em uma melhoria na acurácia superior a 20% quando comparada com as técnicas tradicionais. A abordagem proposta por Pereira e Papa é versátil, podendo ser aplicada em cenários que exigem a exploração de dependências temporais, espaciais ou contextuais das amostras, incluindo, mas não se limitando a, classificação de imagens, séries temporais e processamento de linguagem natural. Outro estudo relevante é o de Pereira et al. [16], que utilizou a Aritmética Intervalar na classificação de eletrofisiologia vegetal, superando a acurácia de métodos baseados em *Deep Learning*.

A aplicação de novos métodos matemáticos na área de IA é essencial para alcançar avanços significativos, visto que toda a espinha dorsal da disciplina é fundamentada em matemática aplicada. Apesar de alguns métodos matemáticos bem consolidados, como o Método de Elementos Finitos (MEF) [11], ainda serem pouco aplicados no âmbito da IA. Para contornar essa fragilidade, o autor desta proposta desenvolveu um conjunto inovador de métodos de aprendizado supervisionado baseados no MEF, denominado FEMa (*Finite Element Machine*). Este *framework*, até o presente momento, é composto por um classificador (FEMaC - *Finite Element Machine Classifier*) [15], um regressor (FEMaR - *Finite Element Machine Regressor*) [2, 13] e um seletor de características (FEMaFS - *Finite Element Machine Feature Selection*) [1]. Os resultados obtidos foram promissores, especialmente em termos de agilidade do método e altas taxas de acurácia, evidenciados pela alta visibilidade e repercussão do artigo referente ao classificador [15], que foi citado significativamente. Contudo, um aperfeiçoamento do método é necessário para atender aplicações de AM que lidam com um grande número de amostras e características, exigindo agilidade no processo de treinamento e teste.

Diante desse panorama, a presente proposta de projeto de pesquisa visa dar continuidade à extensão de métodos matemáticos robustos no contexto da Aprendizagem de Máquina. O foco deste projeto é consolidar e ampliar o FEMa e a Aritmética Intervalar no âmbito da AM, com a expectativa de que, ao final do projeto, sejam alcançados avanços significativos, propiciando contribuições valiosas para a área.

O restante da proposta está organizado da seguinte forma: a Seção 2 apresenta o Referencial Teórico desta proposta; os Objetivos são apresentados na Seção 3; a Justificativa está na Seção 4; a Metodologia e os Resultados Esperados são apresentados nas Seções 5 e 6, respectivamente; o Cronograma de execução é detalhado na Seção 7. A identificação do responsável desta proposta é exibida na Seção 8.

2 Referencial Teórico

Esta seção apresenta o referencial teórico pertinente ao projeto de pesquisa. Para assegurar uma organização adequada, clareza e facilitar a compreensão, esta seção está dividida em duas sub-seções: (i) Método de Elementos Finitos e (ii) Aritmética Intervalar.

2.1 Método de Elementos Finitos

O Método de Elementos Finitos (MEF) é uma metodologia matemática fundamental que tem sido amplamente utilizada para a aproximação de funções com comportamentos complexos. Essa técnica consiste, essencialmente, em subdividir o espaço de uma função em subespaços menores e mais simples. Quando esses subespaços são combinados, eles reconstituem o espaço completo da função original. Nesta sub-seção, serão apresentados alguns dos principais conceitos e aplicações do MEF, destacando sua relevância na área de aprendizado de máquina.

2.1.1 Definições

Considere Γ um conjunto infinito e $\mathbf{V}$ um espaço vetorial não trivial. O espaço $\Gamma \rightarrow \mathbf{V}$ possui dimensão infinita, impossibilitando a representação de um elemento genérico desse espaço em um computador. Essa limitação aplica-se também a muitos subespaços relevantes de $\Gamma \rightarrow \mathbf{V}$, como, por exemplo, funções contínuas e diferenciáveis. Portanto, para fins computacionais, é necessário substituir uma função genérica F do espaço de interesse $\mathbf{F} \subseteq \Gamma \rightarrow \mathbf{V}$ por uma aproximação $\tilde{F}$, escolhida em algum subespaço $\mathbf{A} \subseteq \Gamma \rightarrow \mathbf{V}$ que possua dimensão finita.

A qualidade da aproximação pode ser mensurada pelo valor $\|\tilde{F} - F\|$, onde $\|\cdot\|$ representa qualquer norma definida sobre o espaço $\mathbf{F}$. A função $\tilde{F} - F$ é então denominada erro de aproximação. Uma base de um espaço vetorial $\mathbf{W}$ é uma lista $\phi_1, \phi_2, \dots, \phi_n$ cujos elementos são linearmente independentes, permitindo que todo elemento $w \in \mathbf{W}$ seja obtido por uma combinação linear $\sum_{i=1}^n a_i \phi_i$, onde os coeficientes $a_1, a_2, \dots, a_n$ são números reais. Se $\phi = (\phi_1, \phi_2, \dots, \phi_n)$ representa uma base de $\mathbf{A}$, a aproximação $\tilde{F}$ pode ser representada no computador pelos seus n coeficientes $a_1, a_2, \dots, a_n$.

Uma aplicação básica dos espaços de aproximação é a interpolação de dados discretos. Neste contexto, são fornecidos n pontos $x_1, x_2, \dots, x_n$ do domínio Γ e n valores associados $y_1, y_2, \dots, y_n$ do espaço $\mathbf{V}$. O objetivo consiste em encontrar uma função $B \in \mathbf{A}$ que interpole os pares (x_i, y_i) , satisfazendo a condição:

$$B(x_i) = y_i \quad \text{para todo } i. \quad (1)$$

Se $\mathbf{A}$ é descrito por uma base $\phi = (\phi_1, \phi_2, \dots, \phi_n)$, é necessário encontrar os coeficientes $a_1, a_2, \dots, a_n$ de modo que $\sum_{i=1}^n a_i \phi_i(x_j) = y_j$ para todo j . Isso equivale a resolver o sistema linear:

$$Z a = y, \quad (2)$$

onde a matriz Z representa a influência de cada elemento ϕ_i no ponto x_j , ou seja:

$$Z_{ij} = \phi_i(x_j). \quad (3)$$

Tipos de Bases de Aproximação

Base Interpoladora: Uma base $\phi_1, \phi_2, \dots, \phi_n$ é interpoladora para os pontos $x_1, x_2, \dots, x_n$ se, e somente se:

$$\phi_i(x_j) = \begin{cases} 1 & \text{se } i = j \\ 0 & \text{caso contrário.} \end{cases} \quad (4)$$

Neste caso, os coeficientes a_i que satisfazem (1) são idênticos aos valores y_i associados aos pontos centrais; assim, a matriz Z é a identidade.

Dada uma base de elementos finitos $\phi_1, \phi_2, \dots, \phi_n$ e um conjunto de pontos $X = \{x_1, x_2, \dots, x_n\} \in \Gamma$, pode-se definir, em geral, uma base interpoladora $\hat{\phi}_1, \hat{\phi}_2, \dots, \hat{\phi}_n$ para X , onde cada elemento $\hat{\phi}_i$ é uma combinação linear dos elementos ϕ_i :

$$\hat{\phi}_i(x) = \sum_j U_{ij} \phi_j(x), \quad (5)$$

onde U é a inversa Z^{-1} da matriz Z da base ϕ .

Base Partição da Unidade: Uma base $\phi_1, \phi_2, \dots, \phi_n$ é uma partição da unidade se, e somente se:

$$\phi_i(x) \geq 0 \quad (6)$$

para todo i e todo $x \in \Gamma$, e

$$\sum_{i=1}^n \phi_i(x) = 1 \quad (7)$$

para todo $x \in \Gamma$. Este tipo de base possui a propriedade de suavização; para todo $x \in \Gamma$, vale:

$$a_{\min} \geq \sum_{i=1}^n a_i \phi_i(x) \geq a_{\max}, \quad (8)$$

onde $a_{\min}$ e $a_{\max}$ representam o mínimo e o máximo dos coeficientes de a .

Para cada base $\phi_1, \phi_2, \dots, \phi_n$ com $\phi_i(x) \geq 0$, pode-se definir uma base partição da unidade associada, pela fórmula:

$$\tilde{\phi}_i(x) = \frac{\phi_i(x)}{\sum_{j=1}^n \phi_j(x)}. \quad (9)$$

Base de Elementos Finitos: O suporte de uma função F de $\Gamma \rightarrow \mathbf{V}$, denotado por $\text{sup } F$, é o conjunto de pontos x de Γ onde $F(x)$ é diferente de zero.

Uma base de elementos finitos é uma base $\phi = \{\phi_1, \phi_2, \dots, \phi_n\}$ para um espaço de aproximação $\mathbf{A}$ tal que o suporte de cada ϕ_i é um subconjunto pequeno e compacto de Γ . O significado de "pequeno" varia conforme o contexto, mas, de maneira geral, implica que a medida (comprimento, área, volume, etc.) de $\text{sup } \phi_i$ é da ordem de $\frac{1}{n}$ da medida de Γ . A união dos suportes dos elementos da base ϕ deve cobrir todos os pontos de Γ onde a função F pode ser diferente de zero. O uso de bases de elementos finitos para a aproximação de funções é conhecido como Método de Elementos Finitos.

Base de Elementos Finitos Definidas por Pontos Uma classe especial de bases de elementos finitos é composta por aquelas definidas por pontos. Em uma base ϕ desse tipo, cada elemento finito ϕ_i é associado a um ponto central x_i , que se localiza aproximadamente no centro do seu suporte. Os elementos ϕ_i são definidos a partir desses pontos x_i , utilizando uma fórmula geral que descreve sua estrutura.

Base Radial: Uma base radial é constituída por uma sequência de funções $\phi_1, \phi_2, \dots, \phi_n$, cada uma delas derivada de uma única função-mãe Ψ (*mother function*) que opera sobre a distância entre um ponto x e os pontos x_i de um conjunto finito $\{x_1, x_2, \dots, x_n\}$. A relação é dada pela expressão:

$$\phi_i(x) = \Psi(|x, x_i|), \quad (10)$$

onde $|p, q|$ denota uma medida da distância entre os pontos p e q .

A função-mãe frequentemente utilizada é a função sino gaussiano, expressa como:

$$\Psi(r) = \exp\left(-\frac{1}{2}\left(\frac{r}{r_0}\right)^2\right), \quad (11)$$

onde r_0 é um parâmetro que determina o raio efetivo do suporte. Embora $\Psi(r)$ seja matematicamente positiva para todo r , na prática, pode ser considerada nula para todo $r \geq 4r_0$.

Em geral, as bases radiais não são nem interpoladoras nem partições da unidade. A Figura 1 ilustra alguns elementos de uma base radial.




Figura 1: Elementos de uma base radial para os pontos x_i indicados no eixo horizontal.

Base Radial Normalizada: Ao aplicar a Equação 9 a uma base radial, obtém-se uma base radial normalizada. Neste caso, cada elemento ϕ_i é definido pela fórmula:

$$\phi_i(x) = \frac{\Psi(|x, x_i|)}{\sum_{j=1}^n \Psi(|x, x_j|)}. \quad (12)$$

Embora esse tipo de base não seja interpoladora, ele se classifica como uma partição da unidade. A Figura 2 mostra alguns elementos de uma base radial normalizada.




Figura 2: Elementos de uma base radial normalizada para os pontos x_i indicados no eixo horizontal.

Bases de Shepard: Em uma base de Shepard [18], cada elemento ϕ_i é definido pela fórmula:

$$\phi_i(x) = \frac{w(x, x_i)}{\sum_{j=1}^n w(x, x_j)}, \quad (13)$$

onde w é uma função não-negativa, que tende ao infinito quando x se aproxima de x_i . Essa característica garante que a base de Shepard é interpoladora e também uma partição da unidade. Comumente, a função w é escolhida como uma potência $k \geq 0$ da inversa da distância Euclidiana:

$$w(x, x_i) = \frac{1}{|x - x_i|^k}. \quad (14)$$

A Figura 3 ilustra alguns elementos de bases de Shepard, destacando a variabilidade que pode ser alcançada com diferentes valores de k .




Figura 3: Um elemento da base de Shepard com diferentes valores de k para os pontos x_i indicados no eixo horizontal. (a) $k = 0.5$, (b) $k = 1$, (c) $k = 2$, (d) $k = 3$.

2.1.2 Finite Element Machine Classifier

Nesta subsubseção, será apresentado o Finite Element Machine Classifier (FEMa), um método avançado que se destaca pela sua eficiência na classificação de padrões supervisionados. Fundamentado no robusto Método dos Elementos Finitos, o FEMa é capaz de trabalhar com uma ampla gama de funções base, incluindo Funções de Base Radial, Funções de Base Radial Normalizada, entre outras. Esta

versatilidade teórica permite a formulação de soluções elegantes para bases que podem ou não ser interpoladoras ou formar uma partição da unidade. Assim, o FEMa abre um vasto campo para novos estudos que aplicam elementos finitos em desafios contemporâneos de aprendizado de máquina.

Seja $\mathcal{Z} = \mathcal{Z}_1 \cup \mathcal{Z}_2$ um conjunto de dados dividido em duas partes: treinamento ($\mathcal{Z}_1$) e teste ($\mathcal{Z}_2$). Aqui, o par $(\mathbf{x}_i, y_i) \in \mathcal{Z}$ representa um vetor de características $\mathbf{x}_i \in \mathbb{R}^m$ extraído da amostra i , com y_i indicando o rótulo correspondente. O FEMa é projetado para aprender um conjunto de funções de probabilidade $\mathcal{P}(\mathbf{x}) = \{P_1(\mathbf{x}), P_2(\mathbf{x}), \dots, P_c(\mathbf{x})\}$, onde c é o número de classes e $P_i(\mathbf{x})$ é a probabilidade de que uma amostra $\mathbf{x} \in \mathcal{Z}_1$ seja atribuída à classe i . Portanto, o objetivo do FEMa é aprender múltiplas funções probabilísticas a partir do conjunto de treinamento, possibilitando uma modelagem mais rica e complexa.

Uma característica notável do FEMa é a sua capacidade de operar sem uma etapa de treinamento sob determinadas condições, o que é especialmente vantajoso ao lidar com grandes volumes de dados. Essa possibilidade é particularmente verdadeira para bases que são nativamente interpoladoras, como a base de Shepard. A função de peso é definida como:

$$w(\mathbf{x}, \mathbf{x}_i) = \frac{1}{|\mathbf{x} - \mathbf{x}_i|^k}, \quad (15)$$

onde $|\mathbf{x} - \mathbf{x}_i|$ representa a distância euclidiana entre os pontos. O parâmetro k é crucial, pois controla a suavidade do processo de interpolação e deve ser escolhido com base nas necessidades específicas do usuário.

Em contraste, ao utilizar uma base que não é interpoladora, como funções radiais, é necessário calcular a inversa de uma matriz que codifica a influência de cada elemento de base. Além disso, se a função de base não possui a propriedade de partição da unidade, todas as funções de base devem ser normalizadas. Portanto, embora o FEMa possa ser aplicado a qualquer função de base, destacamos que as bases que são simultaneamente interpoladoras e formam uma partição da unidade se mostram significativamente mais vantajosas para a manipulação de grandes volumes de dados. Nesse contexto, o cálculo da inversa da matriz e o processo de normalização podem ser considerados etapas de treinamento quando se empregam bases não interpoladas e não particionadas.

Supondo que seja utilizado uma base que é tanto interpoladora quanto de partição da unidade (como a base de Shepard), pode-se avançar para a etapa de classificação. Para uma amostra $\mathbf{x} \in \mathcal{Z}_2$, a probabilidade de pertencimento a cada classe i é calculada como segue:

$$P_i(\mathbf{x}) = \sum_{j=1}^{|\mathcal{Z}_1|} \rho_i^j \phi_j(\mathbf{x}), \quad (16)$$

onde $\rho_i^j \in [0, 1]$ representa a probabilidade da amostra de treinamento j ser atribuída à classe i . Uma característica distintiva do FEMa se encontra na capacidade de atribuir uma probabilidade individualizada a cada amostra de treinamento, o que permite a incorporação de uma medida de incerteza intrínseca. Tal funcionalidade é de suma importância especialmente no campo da medicina, onde a variabilidade na interpretação dos dados por especialistas é notória, a utilização de modelos que contemplam essa incerteza torna-se necessária para assegurar robustez dos resultados obtidos. Por exemplo, se uma imagem foi classificada como "indicativa de lesão" por alguns especialistas e como "normal" por outros, o FEMa pode incorporar essa discrepância nas probabilidades, ao invés de forçar uma classificação única e determinística. Isso permite que o modelo reconheça os níveis de incerteza presentes nos dados, contribuindo para decisões mais seguras e fundamentadas.

O FEMa não só proporciona uma abordagem robusta e flexível para a classificação, mas também abre novas possibilidades para o desenvolvimento de modelos que integram incerteza e variabilidade, promovendo uma análise mais precisa e confiável em cenários complexos. Essa capacidade de modelagem probabilística torna o FEMa uma ferramenta poderosa no campo do aprendizado de máquina e na análise de dados em contextos práticos.

A probabilidade $\rho_i^j \in [0, 1]$ pode ser calculada utilizando a seguinte formulação:

$$\rho_i^j = \begin{cases} 1 & \text{se } y_j = i \\ 0 & \text{caso contrário.} \end{cases} \quad (17)$$

Considerando que os conjuntos de dados são rotulados, ou seja, assume-se que o processo de rotulagem não contém erros, podemos restringir ρ_i^j a valores binários, onde $\rho_i^j \in \{0, 1\}$. Assim, geramos o conjunto de probabilidades $\mathcal{P}(\mathbf{x})$ para cada amostra $\mathbf{x} \in \mathcal{Z}_2$.

Em síntese, o FEMa classifica uma amostra específica $\mathbf{x} \in \mathcal{Z}_2$ como pertencente à classe $\hat{y}$, que é obtida através da maximização da probabilidade:

$$\hat{y} = \arg \max_i P_i(\mathbf{x}). \quad (18)$$

Adicionalmente, o FEMa permite a inferência do grau de certeza $C(\mathbf{x})$, calculado da seguinte forma:

$$C(\mathbf{x}) = \frac{P_{\hat{y}}(\mathbf{x})}{\sum_{j=1}^c P_j(\mathbf{x})}. \quad (19)$$

Dessa forma, o FEMa é capaz de produzir saídas que são tanto rigorosas quanto probabilísticas, sem a necessidade de modificações adicionais.

Exemplo Prático Nesta subsubseção, será ilustrado o funcionamento do FEMa em um problema de classificação bidimensional. A Figura 4(a) exibe um conjunto de treinamento com amostras distribuídas em três classes distintas (vermelho, verde e azul). A tarefa consiste em determinar a região de influência de cada amostra de treinamento no domínio da imagem, ou seja, classificar os pontos restantes (brancos) na visualização apresentada na Figura 4(a). Aqui, a única característica considerada para cada amostra (ponto) é sua posição (x, y) .




Figura 4: Mecanismo de trabalho do FEMa: (a) conjunto de treinamento com amostras distribuídas em três classes, e a imagem classificada pelo FEMa utilizando (b) $k = 1$, (c) $k = 3$ e (d) $k = 5$.

As Figuras 4(b), 4(c) e 4(d) apresentam as imagens classificadas pelo FEMa com a base de Shepard, utilizando diferentes valores de k : $k = 1$, $k = 3$ e $k = 5$, respectivamente. Como as coordenadas (x, y) são utilizadas para descrever cada amostra, cada imagem rotulada reflete a região de influência de cada amostra de treinamento, resultando na delimitação das classes. Observa-se que o FEMa consegue estabelecer limites de decisão bastante precisos e suaves para os variados valores de k (ver Equação 15). É importante notar que, quanto maior o valor de k , menor é a influência de pontos específicos no processo de interpolação da função de probabilidade. Para ilustrar, quando $k \rightarrow \infty$, o FEMa tende a se comportar de forma semelhante ao conhecido classificador de vizinho mais próximo (K-nn) [7].

A Figura 5(a) apresenta o grau de certeza (conforme a Equação 19) calculado pelo FEMa com $k = 3$ para cada amostra de teste em relação à Figura 4(a). Pixels mais brilhantes indicam um maior grau de certeza de que o ponto pertence a uma classe específica. Os pixels mais escuros, por sua vez, estão

localizados nas fronteiras entre as classes (ver Figura 4(c)). A Figura 5(b) representa cada amostra de teste, utilizando uma cor correspondente ao seu rótulo, ponderada pelo respectivo grau de certeza.




Figura 5: Mapa de probabilidade (grau de certeza) calculado pelo FEMa em (a) e os rótulos de classe ponderados pelo respectivo grau de certeza em (b).

Análise de Complexidade

Conforme discutido anteriormente, a complexidade do FEMa é diretamente influenciada pela escolha da função base utilizada na construção da classificação probabilística, seja ela interpoladora ou uma que não possua a propriedade de partição da unidade. Quando adotamos uma função base interpoladora, o FEMa não requer uma etapa de treinamento explícita, resultando em uma complexidade de $\theta(1)$. Por outro lado, se optarmos por uma função de base que não seja interpoladora, será necessário calcular a matriz inversa $\mathbf{Z}^{-1}$, conforme descrito na Equação 3. Este cálculo, utilizando o algoritmo de Coppersmith-Winograd [3], requer uma complexidade de $\theta(|\mathcal{Z}_1|^{2.37})$.

Na fase de classificação, para cada amostra de teste $\mathbf{x}$, precisamos calcular a Equação 14, que exige uma complexidade de $\theta(|\mathcal{Z}_1|)$. Entretanto, o denominador dessa equação, que considera todas as amostras de treinamento, se torna uma constante após seu cálculo inicial, ou seja, ele precisa ser computado apenas uma vez. Como o conjunto de teste contém $|\mathcal{Z}_2|$ amostras, a complexidade geral da fase de classificação se torna $\theta(|\mathcal{Z}_1| + |\mathcal{Z}_1||\mathcal{Z}_2|) \in \theta(|\mathcal{Z}_1||\mathcal{Z}_2|)$. Portanto, ao utilizar uma função de base interpoladora, tanto o aprendizado quanto o processo de classificação do FEMa apresentam uma complexidade quadrática em relação ao tamanho dos conjuntos de treinamento e teste, especialmente quando temos $|\mathcal{Z}_1| = |\mathcal{Z}_2|$.

Entretanto, em cenários de conjuntos de dados desbalanceados, onde as amostras das classes majoritárias exercem uma influência desproporcional no cálculo das funções de probabilidade, a situação se torna mais complexa. Considere um problema de classificação binária, onde temos amostras positivas e negativas, sendo que as amostras da classe negativa representam apenas 1% do total de amostras positivas. Nesse caso, ao calcular a função de probabilidade para uma amostra de teste, as amostras positivas desempenham um papel predominante nesse processo de computação.

Para mitigar essa influência desbalanceada, uma abordagem eficaz é utilizar apenas as T amostras de treinamento mais próximas de cada classe, onde $T \in O(\alpha)$ e α denota o número de elementos da menor classe. Neste cenário, a classificação das amostras de treinamento com base nas distâncias relativas a cada amostra de teste resulta em uma complexidade de $\theta((|\mathcal{Z}_1| \log |\mathcal{Z}_1|) |\mathcal{Z}_2|)$.

Além disso, podemos otimizar esse processo empregando estruturas de dados especiais, como *kdtrees* [17], que possibilitam um carregamento eficiente dos dados, requerendo apenas $\theta(|\mathcal{Z}_1| \log |\mathcal{Z}_1|)$ durante a fase de treinamento. Na fase de classificação, eliminamos a necessidade de ordenação, uma vez que obter as T amostras mais próximas leva $O(T \log |\mathcal{Z}_1|)$. Portanto, a complexidade da fase de classificação, quando aplicada essa otimização, é dada por $\theta((T \log |\mathcal{Z}_1|) |\mathcal{Z}_2|)$.

Este refinamento na análise de complexidade é crucial para garantir a eficiência do FEMa em diversos contextos de aplicação, principalmente em cenários onde a desbalanceamento de classes pode impactar significativamente os resultados de classificação. Assim, a adaptação das estratégias de aprendizado e a utilização de estruturas de dados adequadas permitem melhorar o desempenho do modelo, tornando-o mais robusto e escalável.

2.2 Aritmética Intervalar

2.2.1 Conceitos Gerais

A Aritmética Intervalar, proposta por Moore na década de 1960 [4–6], é um modelo de computação baseado em intervalos, no qual cada intervalo $[x]$ é representado por uma faixa não-vazia de valores reais $[x_l, x_h]$. Esse intervalo representa o subconjunto dos números reais $\mathbb{R}$ que satisfaz a seguinte condição:

$$\{r \in \mathbb{R}^* \mid x_l \leq r \leq x_h\}. \quad (20)$$

A fundamentação teórica da Aritmética Intervalar (Arl) estabelece um conjunto de relações e operações que podem ser realizadas ao longo dos intervalos [4–6]. Dessa forma, é possível comparar, unir, somar e até multiplicar intervalos de números, tornando-se uma ferramenta mais poderosa do que a aritmética tradicional. Qualquer número real $r \in \mathbb{R}$ pode ser representado pelo intervalo singular $[r, r]$. Além disso, a Aritmética Intervalar é um mecanismo valioso para fornecer representações eficientes de limites de erro e incertezas. A seguir, são apresentadas as definições das principais operações com intervalos:

Interseção: A interseção entre dois intervalos $[x]$ e $[y]$ é definida como:

$$[x] \cap [y] = [\max\{x_l, y_l\}, \min\{x_h, y_h\}], \quad (21)$$

sendo válida apenas quando $\max\{x_l, y_l\} \leq \min\{x_h, y_h\}$.

União: A união entre dois intervalos $[x]$ e $[y]$ é definida apenas para intervalos que não apresentam interseção vazia, ou seja, quando $[x] \cap [y] \neq \emptyset$:

$$[x] \cup [y] = [\min\{x_l, y_l\}, \max\{x_h, y_h\}]. \quad (22)$$

Fecho Convexo: O fecho convexo de dois intervalos $[x]$ e $[y]$ é o menor intervalo que contém ambos:

$$[x] \bar{\cup} [y] = [\min\{x_l, y_l\}, \max\{x_h, y_h\}]. \quad (23)$$

Embora a formulação acima seja idêntica à apresentada na Equação 22, ela não requer a condição de interseção vazia.

A Aritmética Intervalar também define primitivas de comparação, conforme segue:

Igualdade: $[x] = [y] \iff x_l = y_l \text{ e } x_h = y_h$

Menor que: $[x] < [y] \iff x_h < y_l$

Menor ou igual que: $[x] \leq [y] \iff x_h \leq y_l$

Maior que: $[x] > [y] \iff x_l > y_h$

Maior ou igual que: $[x] \geq [y] \iff x_l \geq y_h$

As operações aritméticas básicas também foram estendidas para intervalos:

Soma: $[x] + [y] = [x_l + y_l, x_h + y_h]$

Negações: $-[x] = [-x_h, -x_l]$

Subtração: $[x] - [y] = [x] + (-[y]) = [x_l - y_h, x_h - y_l]$

Multiplicação:

$$[x] \cdot [y] = [\min\{x_l y_l, x_l y_h, x_h y_l, x_h y_h\}, \max\{x_l y_l, x_l y_h, x_h y_l, x_h y_h\}].$$

Essas operações formam a base da Aritmética Intervalar, permitindo um tratamento mais robusto de incertezas e erros em diversas aplicações computacionais.

2.2.2 Aplicação em Aprendizado de Máquina Contextual

A Aritmética Intervalar já foi utilizada pelo autor desta proposta para modelar uma imagem usando uma representação multi-escala, com o intuito de melhorar a classificação contextual de imagens de satélite. Assim, dada uma imagem de entrada I com $n_x \times n_y$ pixels e um fator de redução α , são construídas S versões da imagem I , ou seja, $I^{(1)}, \dots, I^{(S)}$, onde $S = S^{max} - 1$ e $S^{max} = \log_{\alpha}(\min\{n_x, n_y\})$.

Observe que a imagem na escala $I^{(S)}$ possui aproximadamente 1×1 *pixels* de resolução, enquanto $I^{(0)}$ representa a imagem original. Ao combinar a Aritmética Intervalar e a representação multi-escala, o conjunto de características é definido ao longo de regiões maiores, explorando a dependência espacial dos *pixels*, que não é possível ser analisada utilizando apenas as cores de um único *pixel*.

Para um *pixel* $(x, y) \in I^{(0)}$, uma janela quadrada de tamanho $(2\alpha^i + 1) \times (2\alpha^i + 1)$ é centrada, e o brilho de todos os *pixels* que se encontram no interior desta janela é representado por um intervalo de valores. Em seguida, os limites inferior e superior do intervalo são calculados usando o operador Fecho Convexo da Aritmética Intervalar (Equação 23), além do valor médio do brilho dos *pixels*. O mesmo procedimento é aplicado para cada $I^{(i)}$, $i \in \{1, 2, \dots, S\}$, e os valores calculados em cada escala são, então, concatenados¹ em um vetor de característica único para todo *pixel* $(x, y) \in I^{(0)}$. Independentemente da escala, os *patches* são sempre calculados em relação à imagem original, estando centrados no *pixel* $(x, y) \in I^{(0)}$.

As imagens na escala i representam os limites inferiores e superiores, bem como os valores médios; que são denotados por $I_{lo}^{(i)}$, $I_{hi}^{(i)}$ e $I_{avg}^{(i)}$, respectivamente. As pirâmides dos limites inferior e superior são compostas por imagens que codificam a incerteza dos *pixels* dentro dessa vizinhança, e a imagem média representa uma informação adicional sobre o comportamento dos *pixels* que pertencem a esse intervalo. A Figura 2.2.2 ilustra um exemplo do processo de decomposição proposto com $S = 3$ e as imagens geradas em cada escala.




Figura 6: Combinação da representação usando pirâmide de imagens e Aritmética Intervalar para definição dos limites inferior e superior, bem como a sua média.

Após a geração da decomposição piramidal, obtém-se um novo conjunto de características estendidas para cada *pixel*, composto de $S + 1$ intervalos e $S + 1$ escalares (o valor médio do intervalo em cada escala). O intervalo da escala i é representado por $r_i = [I_{lo}^{(i)}(x\alpha^i, y\alpha^i), I_{hi}^{(i)}(x\alpha^i, y\alpha^i)]$, e a média na mesma escala é representada por $I_{avg}^{(i)}(x\alpha^i, y\alpha^i)$. Portanto, o novo vetor de características $\mathbf{f}^*_{(x,y)}$ para cada *pixel* $(x, y) \in I$ é representado por:

$$\mathbf{f}^*_{(x,y)} = \left\{ \begin{array}{l} I(x, y), \\ \left[I_{lo}^{(1)}\left(\frac{x}{\alpha^1}, \frac{y}{\alpha^1}\right), I_{hi}^{(1)}\left(\frac{x}{\alpha^1}, \frac{y}{\alpha^1}\right) \right], I_{avg}^{(1)}\left(\frac{x}{\alpha^1}, \frac{y}{\alpha^1}\right), \\ \dots, \\ \left[I_{lo}^{(S)}\left(\frac{x}{\alpha^S}, \frac{y}{\alpha^S}\right), I_{hi}^{(S)}\left(\frac{x}{\alpha^S}, \frac{y}{\alpha^S}\right) \right], I_{avg}^{(S)}\left(\frac{x}{\alpha^S}, \frac{y}{\alpha^S}\right) \end{array} \right\}$$

¹Note que a janela é sempre centrada no *pixel* $(x, y) \in I^{(0)}$, mesmo para diferentes escalas $I^{(i)}$, $i \in \{1, 2, \dots, S\}$.

Os resultados obtidos pela metodologia foram significativamente superiores às metodologias da literatura (como *Sequential Stacked Learning* - SSL, *Multi-resolution Sequential Stacked Learning* - MRSSL, *Pyramidal Sequential Stacked Learning* - PYRSSL, e *Sliding Window* - SW), alcançando as melhores acurácias e se destacando por ser a mais rápida [12]. Essa aplicação resultou em uma melhoria na acurácia superior a 20% quando comparada com as técnicas tradicionais.

3 Objetivos

O presente projeto tem como objetivo principal expandir e aplicar metodologias matemáticas inovadoras no campo do Aprendizado de Máquina, com foco na utilização do Método de Elementos Finitos e da Aritmética Intervalar, visando a criação de algoritmos mais robustos, eficientes e adaptáveis às complexidades dos dados modernos. Para alcançar este objetivo, foram estabelecidos os seguintes objetivos específicos:

1. Desenvolver e aplicar o Método de Elementos Finitos em algoritmos de AM, com o intuito de explorar sua capacidade de modelar problemas complexos e heterogêneos de maneira precisa e eficiente.
2. Aprimorar o *framework* FEMa, previamente desenvolvido pelo proponente, visando expandir suas funcionalidades para abordar desafios emergentes no contexto do AM, fortalecendo sua aplicabilidade e relevância prática.
3. Aplicar a Aritmética Intervalar em cenários que envolvem dependências espaciais e temporais, explorando sua capacidade de lidar com incertezas e variabilidades de forma robusta, de modo a melhorar a confiabilidade dos modelos gerados.

Dessa forma, o projeto busca contribuir significativamente para o avanço científico e tecnológico do AM, ampliando os limites das metodologias matemáticas aplicáveis e promovendo o desenvolvimento de soluções eficazes e impactantes para problemas complexos e multidisciplinares.

4 Justificativa

Nos últimos anos, o campo do Aprendizado de Máquina tem experimentado avanços notáveis, impulsionados em grande parte pela aplicação e combinação de métodos matemáticos e estatísticos inovadores. Destacam-se, neste contexto, a Aritmética Intervalar e o Método de Elementos Finitos, ambos introduzidos no domínio do AM pelo proponente desta pesquisa. Essas técnicas, até então pouco exploradas nesse âmbito, demonstraram um potencial significativo para testar os limites do que é possível alcançar em termos de desempenho e precisão dos modelos de AM.

Neste cenário, a proposta de pesquisa apresentada visa expandir e aplicar de forma abrangente essas metodologias matemáticas, inserindo-as no contexto do AM. O projeto se fundamenta na premissa de que a integração desses métodos não convencionais pode catalisar avanços substanciais na área, possibilitando a criação de algoritmos mais robustos, eficientes e adaptáveis às complexidades dos dados modernos.

A pesquisa será estruturada em três frentes principais:

- **Utilização do Método de Elementos Finitos (FEM):** Serão exploradas as capacidades do FEM para o desenvolvimento de novos algoritmos de AM, aproveitando sua habilidade de modelar problemas complexos e heterogêneos de maneira precisa e eficiente.
- **Aprimoramento do Framework FEMa:** O *framework* FEMa, previamente desenvolvido pelo proponente, será refinado e expandido para abordar desafios emergentes e específicos do AM, fortalecendo sua aplicabilidade e relevância prática. Este aprimoramento buscará integrar novas funcionalidades que potencializem o uso do FEM em contextos de aprendizado de máquina.
- **Aplicação da Aritmética Intervalar em Contextos Espaciais e Temporais:** A metodologia de ArI será aplicada em cenários que envolvem dependências espaciais e/ou temporais, explorando sua capacidade de lidar com incertezas e variabilidades de forma mais robusta e precisa. Esta

aplicação permitirá um tratamento mais eficaz das incertezas inerentes aos dados, melhorando a confiabilidade dos modelos gerados.

Em suma, este projeto representa uma iniciativa desafiadora, inovadora e oportuna para integrar e ampliar o uso de metodologias matemáticas pouco exploradas no AM, visando contribuir de maneira significativa para o avanço científico e tecnológico da área. A combinação dessas abordagens não apenas busca aprimorar os métodos existentes, mas também abrir novas fronteiras para a aplicação de AM em problemas complexos.

5 Metodologia

A presente proposta de pesquisa será estruturada em duas grandes frentes de investigação: (i) o aprimoramento do *framework* FEMa, incluindo a criação de novos métodos não supervisionados e semi-supervisionados, além da otimização de algoritmos por meio de estruturas de dados avançadas; e (ii) a aplicação e expansão da Aritmética Intervalar em tarefas de classificação de imagens, previsões de séries temporais e problemas de AM que requerem análise contextual.

5.1 Extensão e Otimização do *Framework* FEMa

O aprimoramento do FEMa focará em dois aspectos principais: a criação de novos métodos e a otimização de desempenho. As etapas metodológicas incluem:

1. **Criação de Novos Métodos Baseados no FEMa:** Extensões do *framework* FEMa para aprendizado não supervisionado, semi-supervisionado e aprendizado ativo. Esses novos métodos utilizarão o conceito de elementos finitos para modelar relações intrínsecas nos dados e explorarão estruturas de similaridade para identificar padrões sem a necessidade de rotulação. O método semi-supervisionado integrará amostras rotuladas e não rotuladas para maximizar a eficiência do aprendizado.
2. **Otimização com Estruturas de Dados Avançadas:** Serão utilizadas estruturas de dados eficientes, como árvores de busca multidimensionais e grafos esparsos, para acelerar as operações computacionais realizadas pelo FEMa. Essas otimizações visam reduzir significativamente os tempos de treinamento e predição, permitindo a aplicação em cenários de grande escala.
3. **Aplicações Específicas do FEMa:** O FEMa será aplicado a problemas práticos, como classificação de grandes volumes de dados médicos, análise de dados climáticos e previsão de consumo energético.

5.2 Aritmética Intervalar (ArI)

A ArI será explorada como ferramenta principal para lidar com incertezas e dependências contextuais em diferentes tarefas de AM. A abordagem metodológica será dividida nas seguintes etapas:

1. **Classificação de Imagens:** Inicialmente, será aplicada a metodologia desenvolvida por Pereira e Papa [12], utilizando a ArI na classificação contextual de imagens em diferentes contextos. O método será ampliado e ajustado para outras aplicações de imagens, como classificação de padrões médicos em radiologia e análise de imagens agrícolas.
2. **Previsões em Séries Temporais:** Adaptações serão realizadas para aplicar a ArI em séries temporais. Será investigado o uso de abordagens baseadas em janelas deslizantes, associando intervalos de incerteza às previsões realizadas, com o objetivo de capturar dependências temporais e melhorar a robustez dos modelos. Aplicações em previsão de consumo energético e análise de dados financeiros serão exploradas.

6 Resultados Esperados

Os resultados esperados desta pesquisa são descritos a seguir:

1. Extensão do *Framework* FEMa:

- Implementação de métodos não supervisionados e semi-supervisionados baseados no FEMa, ampliando o alcance do *framework*.
- Redução significativa no tempo de treinamento e teste por meio da incorporação de estruturas de dados avançadas.
- Aplicação do FEMa em problemas reais, e comparação com os outros métodos de AM.

2. Aritmética Intervalar:

- Demonstração da eficácia da ArI na classificação de imagens, com expectativa de ganhos em acurácia e principalmente em relação as abordagens existentes.
- Melhoria na robustez e precisão das previsões de séries temporais, especialmente em cenários com alta variabilidade e incerteza.

3. Contribuições Gerais:

- Publicação de artigos científicos em periódicos de alto impacto, detalhando as metodologias e os resultados alcançados.
- Orientações de aluno de Iniciação Científica, Mestrado e Doutorado na temática do projeto.
- Desenvolvimento de ferramentas computacionais baseadas no FEMa e na ArI, disponibilizadas para a comunidade acadêmica.
- Consolidação da relevância de métodos matemáticos, como a ArI e o FEMa, no avanço da área de IA.

7 Cronograma

O projeto será desenvolvido ao longo de 36 meses, dividido em períodos semestrais. As atividades foram planejadas de modo garantir o progresso contínuo e a entrega dos resultados esperados em cada etapa. A Tabela 1 apresenta o cronograma.

Tabela 1: Cronograma de Atividades por Semestres.

Legenda: S1 – 1º semestre, S2 – 2º semestre, ..., S6 – 6º semestre.

Atividades	S1	S2	S3	S4	S5	S6
Extensão e Otimização do <i>Framework</i> FEMa						
Criação de novos métodos (não supervisionados e semi-supervisionados)	X	X	X			
Otimização com estruturas de dados avançadas		X	X	X	X	X
Aplicações específicas do FEMa	X	X	X	X		
Expansão da Aritmética Intervalar (ArI)						
Classificação de imagens			X	X	X	X
Previsão em séries temporais			X	X	X	X
Publicações e Disseminação de Resultados						
Escrita e submissão de artigos científicos		X	X	X	X	X
Apresentação de resultados em eventos e conferências			X	X	X	X

8 Identificação dos Participantes do Projeto

A colaboração entre o autor deste projeto de pesquisa e os pesquisadores envolvidos tem gerado um impacto significativo, resultando em publicações em periódicos internacionais de prestígio nas áreas de Ciência da Computação e Engenharia, além da participação ativa em congressos nacionais e internacionais.

A seguir, são apresentados os resumos das qualificações de cada membro da equipe envolvida no projeto.

Danillo Roberto Pereira - *Candidato da proposta*

Danillo possui graduação em Ciência da Computação pela FCT-UNESP (2006), mestrado em Ciência da Computação com ênfase em Computação Gráfica e Método de Elementos Finitos pela UNICAMP (2009), doutorado em Ciência da Computação com foco em Processamento de Imagens, Otimização Não-Linear e Computação Visual pela UNICAMP (2013), e pós-doutorados em Inteligência Artificial pela FC-UNESP (2016) e em Aprendizado de Máquina pelo DC-UFSCAR (2017). Com um histórico acadêmico robusto, foi professor da Universidade do Oeste Paulista (Unoeste) por sete anos e atuou como docente permanente no Mestrado e Doutorado em Meio Ambiente e Desenvolvimento Regional (MMADRE) da mesma instituição por três anos. Danillo detém um número de Erdős de 4.

De janeiro de 2018 a junho de 2023, ele publicou 45 artigos em periódicos, sendo 20 internacionais e 25 nacionais, além de 4 artigos completos em eventos internacionais. Durante esse período, o candidato também depositou 2 patentes, uma no Brasil e outra nos Estados Unidos.

Nos últimos cinco anos, Danillo orientou 2 mestrados na Unoeste e co-orientou 2 iniciações científicas. Ele atuou como revisor para 11 periódicos de renome, dos quais 10 são internacionais. Danillo é revisor da FAPES (Fundação de Amparo à Pesquisa do Espírito Santo).

Em 2016, participou de um *sprint* promovido pela FAPESP/BAYLAT na Friedrich-Alexander-Universität (FAU), com todas as despesas custeadas pela FAPESP/BAYLAT. Em novembro do mesmo ano, esteve em Cambridge por 12 dias, estreitando laços com o pesquisador Xin-She Yang, o que resultou na publicação de 2 capítulos de livro, 1 artigo em congresso internacional e 1 artigo em periódico internacional com o referido pesquisador.

Em 2016, co-fundou a *startup* Cristall Ball, cujo projeto PIPE (Pesquisa Inovativa em Pequenas Empresas - Fase 1) da FAPESP foi aprovado. A Cristall Ball focava na aplicação de Inteligência Artificial em negócios para aumentar lucros e reduzir custos. Em dezembro de 2017, a Cristall Ball foi parcialmente vendida a um grupo de investidores norte-americanos, tornando-se a Analytics2Go, que atualmente conta com mais de 30 colaboradores e desenvolve projetos no Brasil e nos EUA. Danillo atuou como Diretor de Data Science e Chief Analytics Officer na Analytics2Go nos últimos cinco anos.

Além disso, Danillo é membro colaborador ativo do laboratório Recogna (*Biometric & Pattern Recognition Research Group*) da UNESP de Bauru.

Xin-She Yang - *Colaborador do projeto*

Xin-She Yang é professor e pesquisador sênior na Middlesex University e em Cambridge, e possui um extenso histórico de colaboração com Danillo em pesquisas sobre métodos de otimização. Ele é responsável pela criação de diversos métodos heurísticos bio-inspirados, sendo uma referência na área. Xin-She contribuirá nas discussões sobre a otimização de parâmetros de modelos LLM e na produção de artigos científicos.

João Paulo Papa - *Colaborador do projeto*

João Paulo é Bolsista de Produtividade em Pesquisa do CNPq e participará do projeto nas discussões sobre as aplicações dos métodos matemáticos, com foco na análise dos resultados do classificador FEMa. Ele e Danillo têm trabalhado em conjunto nos últimos 10 anos, publicando numerosos artigos em periódicos e congressos internacionais.

João Paulo é graduado em Sistemas de Informação pela Universidade Estadual Paulista Júlio de Mesquita Filho (2002), mestre em Ciência da Computação pela Universidade Federal de São Carlos

(2005), doutor em Ciência da Computação pela Universidade Estadual de Campinas (2008), e realizou pós-doutorados em Ciência da Computação pela UNICAMP (2009) e em Harvard University (2015). Atualmente, é Professor Assistente Doutor no Departamento de Computação da UNESP-Bauru e pesquisador colaborador no Instituto de Computação da UNICAMP. Ele tem experiência na área de Ciência da Computação, com ênfase em Sistemas de Computação, atuando em temas como processamento de imagens, aprendizado de máquina e reconhecimento de padrões.

João Paulo é membro de diversos Grupos de Pesquisa, incluindo Recogna - Biometric & Pattern Recognition Research Group (UNESP), Sistemas Computacionais Avançados (UNESP), Grupo de Arquiteturas, Processamento de Imagens e Sinais (UFSCAR) e Processamento de Imagens (UNICAMP). Já orientou vários alunos de mestrado e doutorado e está entre os cientistas mais influentes do mundo, conforme o ranking global da Stanford e da Clarivate Analytics de 2019, posicionando-se entre os 1% mais citados.

Referências

- [1] L. Biaggi, J. P. Papa, K. A. P. Costa, D. R. Pereira, and L. A. Passos. Fema-fs: Finite element machines for feature selection. In *2022 26th International Conference on Pattern Recognition (ICPR)*, 2022.
- [2] D. Colombo, G. B. Alves Lima, D. R. Pereira, and J. P. Papa. Regression-based finite element machines for reliability modeling of downhole safety valves. *Reliability Engineering & System Safety*, 198, 2020.
- [3] D. Coppersmith and S. Winograd. Matrix multiplication via arithmetic progressions. *Journal of Symbolic Computation*, 9:251–280, 1990.
- [4] R. E. Moore. *Interval Analysis*. Prentice-Hall, Englewood Cliff, New Jersey, 1966.
- [5] R. E. Moore. Methods and applications of interval analysis. *SIAM Studies in Applied Mathematics*, 1979.
- [6] R. E. Moore and C. T. Yang. Interval analysis I. Technical Document LMSD-285875, Lockheed Missiles and Space Division, Sunnyvale, CA, USA, 1959.
- [7] J. Pan, Y. Qiao, and S. Sun. A fast k nearest neighbors classification algorithm. *IEICE Transactions on Fundamentals of Electronics, Communications and Computer Sciences*, E87-A, 2004.
- [8] J. P. Papa, L. P. Papa, R. Pisani, and D. R. Pereira. Unsupervised land-cover classification through hyper-heuristic-based harmony search. In *2015 IEEE International Geoscience and Remote Sensing Symposium, IGARSS 2015, Milan, Italy, July 26-31, 2015*, pages 69–72, 2015.
- [9] C. R. Pereira, D. R. Pereira, F. A. da Silva, C. Hook, S. A. T. Weber, L. A. M. Pereira, and João Paulo Papa. A step towards the automated diagnosis of parkinson’s disease: Analyzing handwriting movements. In *28th IEEE International Symposium on Computer-Based Medical Systems, CBMS 2015, Sao Carlos, Brazil, June 22-25, 2015*, pages 171–176, 2015.
- [10] D. Pereira, R. Pisani, R. Nakamura, and J. Papa. Land-cover classification through sequential learning-based optimum-path forest. In *2015 IEEE International Geoscience and Remote Sensing Symposium, IGARSS 2015, Milan, Italy, July 26-31, 2015*, pages 76–79, 2015.
- [11] D. R. Pereira. Representação e cálculo eficiente da iluminação global na síntese de imagem. Master’s thesis, Institute of Computing, University of Campinas, 2009.
- [12] D. R. Pereira and J. P. Papa. A new approach to contextual learning using interval arithmetic and its applications for land-use. *Pattern Recognition Letters*, 2016.
- [13] D. R. Pereira, J. P. Papa, and Andre N. Souza. Femar: A finite element machine for regression problems. In *2017 International Joint Conference on Neural Networks (IJCNN)*, pages 2751–2757, 2017.

- [14] D. R. Pereira, M. A. Pazoti, L. A. M. Pereira, D. Rodrigues, C. C. O. Ramos, A. N. de Souza, and J. P. Papa. Social-spider optimization-based support vector machines applied for energy theft detection. *Computers & Electrical Engineering*, 49:25–38, 2016.
- [15] D. R. Pereira, M. A. Piteri, A. N. Souza, J. P. Papa, and H. Adeli. Fema: a finite element machine for fast learning. *Neural Computing and Applications*, pages 6393–6404, 2020.
- [16] Danilo Roberto Pereira, João Paulo Papa, Gustavo Francisco Rosalin Saraiva, and Gustavo Maia Souza. Automatic classification of plant electrophysiological responses to environmental stimuli using machine learning and interval arithmetic. *Computers and Electronics in Agriculture*, 145:35–42, February 2018.
- [17] Parikshit Ram and Kaushik Sinha. Revisiting kd-tree for nearest neighbor search. In *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, KDD ’19, page 1378?1388, New York, NY, USA, 2019. Association for Computing Machinery.
- [18] D. Shepard. A two-dimensional interpolation function for irregularly-spaced data. In *Proceedings of 23rd ACM national conference*, pages 517–524. ACM Press, 1968.